Facultad de Ingeniería de la Universidad Nacional de Asunción

Inteligencia Artificial
2026

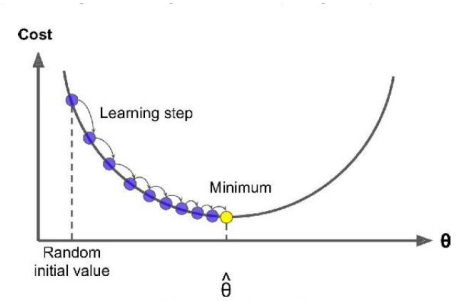

Figure 4-3. Gradient Descent

Diego Stalder

Christian Torres

Contenido

- Introducción a la Regularización:
  - Definición de regularización y su importancia.
  - Explicación de los problemas asociados al sobreajuste.
- Tipos de Regularización:
  - L1 Regularización (Lasso).
  - L2 Regularización (Ridge).
  - Elastic Net (combinación de L1 y L2).
- Función de Costo con Términos de Regularización:
  - Adición de términos de regularización a la función de costo.
  - Balance entre términos de ajuste y regularización.
- Gradiente Descendente Regularizado:
  - Modificación del algoritmo de gradiente descendente para incluir términos de regularización.
  - Actualización de los pesos de acuerdo con la derivada de la función de costo regularizada.
- Efectos de la Regularización:
  - Demostración de cómo la regularización afecta la convergencia del modelo.
  - Comparación de modelos con y sin regularización.
- Selección del Parámetro de Regularización:
  - Importancia de ajustar correctamente el parámetro de regularización.
  - Métodos para seleccionar el parámetro óptimo (validación cruzada).

El problema del "Overfitting"

Ejemplo: Regresión lineal

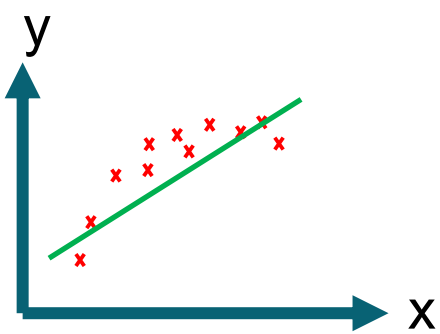

$\theta_0 + \theta_1 \; x$

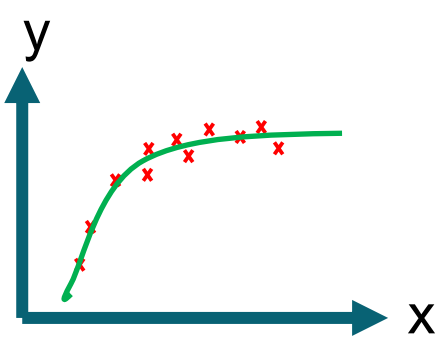

$\theta_0 + \theta_1 \, x + \theta_2 \, x^2$

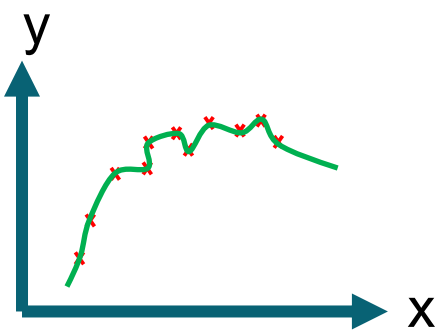

$\theta_0 + \theta_1 \, x + \theta_2 \, x^2 + \theta_3 \, x^3 + \theta_4 x^4$

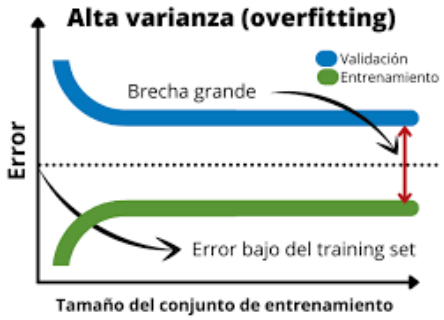

Underfitting

Entreno al modelo con
1 sóla raza de perro

Muestra nueva:
¿Es perro?

NO

FALLO

La máquina fallará en reconocer al perro por falta de suficientes muestras. No puede generalizar el conocimiento.

Overfitting

Entreno al modelo con
10 razas de perro color marrón

Muestra nueva:
¿Es perro?

NO

FALLO

La máquina fallará en reconocer un perro nuevo porque no tiene estrictamente los mismos valores de las muestras de entrenamiento.

Es un problema del modelo al Generalizar

Regularización

La regularización L2, también conocida como regularización de Ridge, es una técnica comúnmente utilizada en el aprendizaje automático para evitar el sobreajuste (overfitting) de un modelo a los datos de entrenamiento.

minimizar $F(w) = (Aw - b)(Aw - b)^T$

$$J_{\mathbf{X},\mathbf{y}}(\mathbf{w}) = \frac{1}{2}\sum_i \left(y^i - \sum_j w_j \phi_j(\mathbf{x}^i) \right)^2 + \frac{\lambda}{2}\|\mathbf{w}\|^2$$

$$J(\theta) = \mathrm{MSE}(\theta) + \alpha \frac{1}{2} \sum_{i=1}^{n} \theta_i^2$$

$$\text{suma residuos cuadrados} + \lambda \sum_{j=1}^{p} \beta_j^2$$

Regularización:
λ pequeño

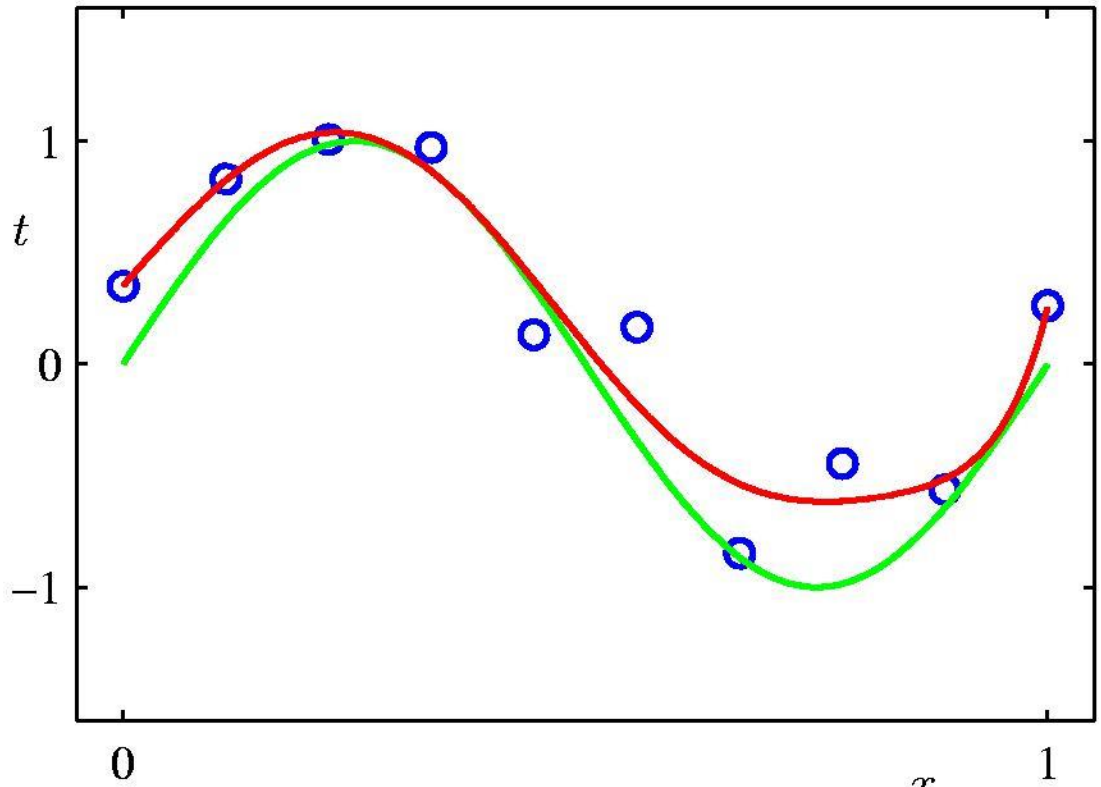

$$J_{\mathbf{X},\mathbf{y}}(\mathbf{w}) = \frac{1}{2}\sum_i \left(y^i - \sum_j w_j \phi_j(\mathbf{x}^i) \right)^2 + \frac{\lambda}{2}\|\mathbf{w}\|^2$$

Sobre regularización:

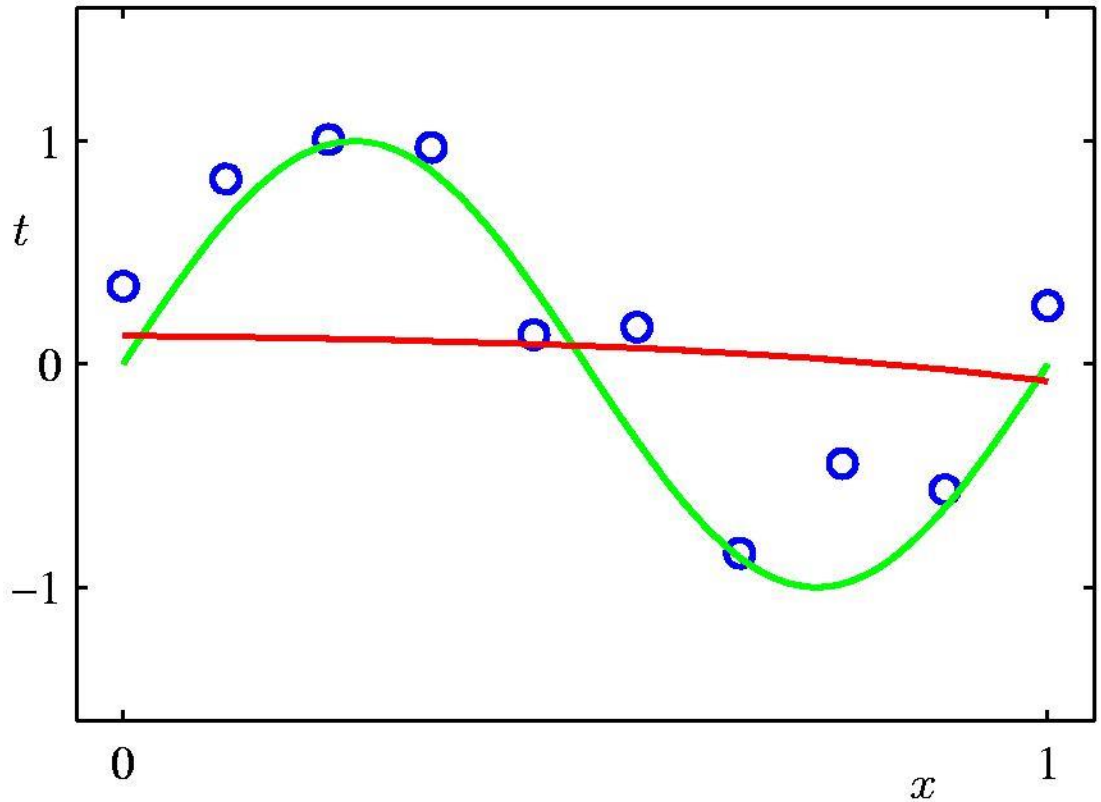

$$J_{\mathbf{X},\mathbf{y}}(\mathbf{w}) = \frac{1}{2}\sum_i \left(y^i - \sum_j w_j \phi_j(\mathbf{x}^i) \right)^2 + \frac{\lambda}{2}\|\mathbf{w}\|^2$$

Lasso

$$J(\theta) = \mathrm{MSE}(\theta) + \alpha \sum_{i=1}^{n} |\theta_i|$$

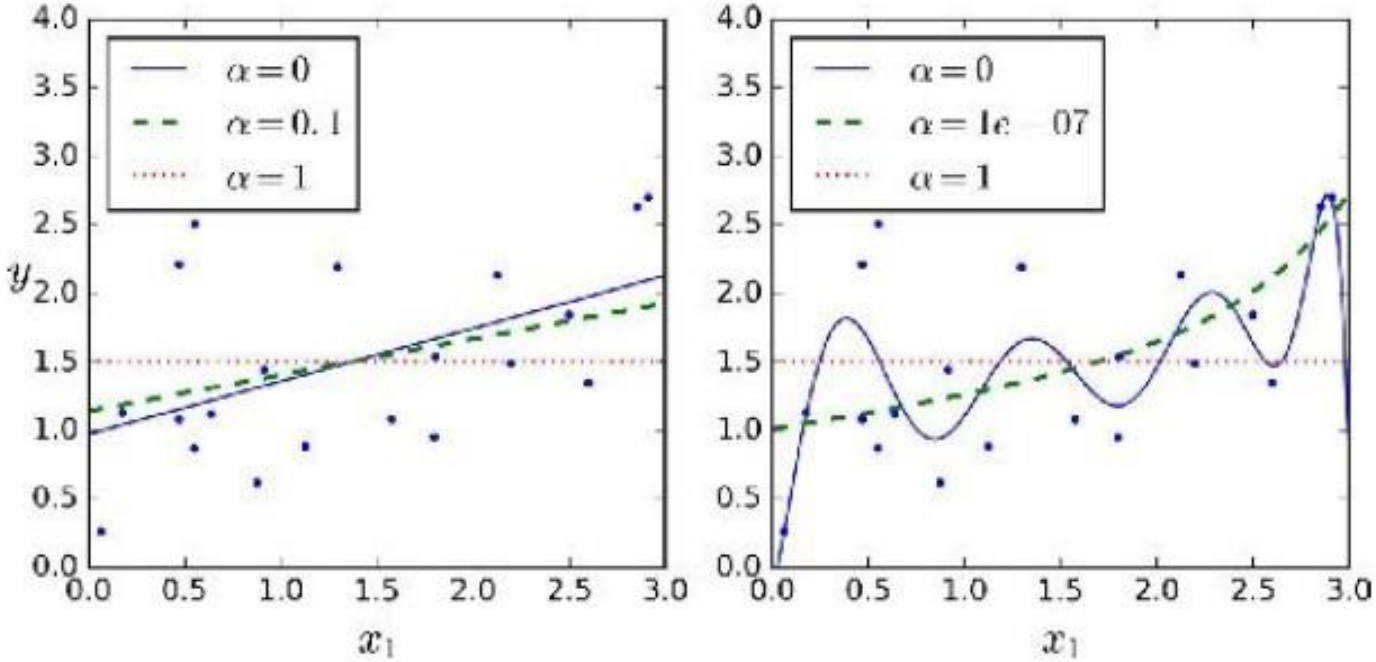

Figure 4-18. Lasso Regression

Elastic Net

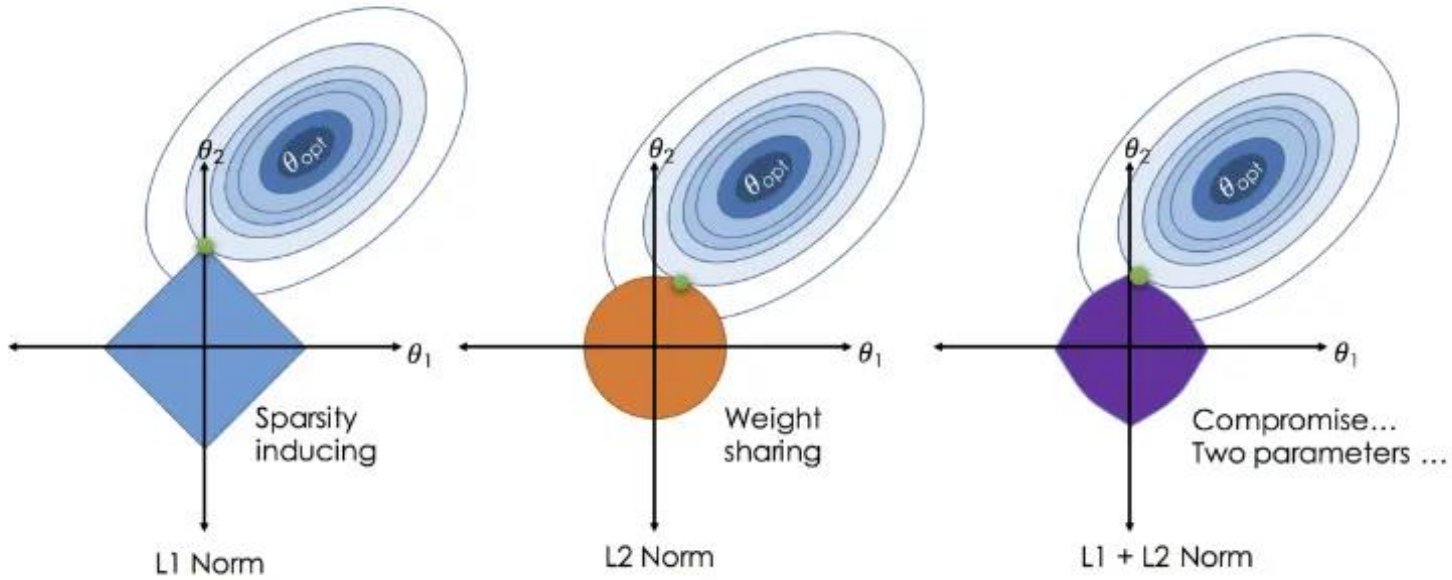

$$\lambda(\alpha \sum_{j=1}^{p} |\beta_j| + \frac{1-\alpha}{2} + \sum_{j=1}^{p} \beta_j^2$$